§6.1 单因素方差分析

通常把生产实践与科学实验中的结果，如产品的性能，产量等统称为指标，影响指标的因素用 $A, B, C, \cdots$，表示。因素在试验中所取的不同状态称为水平，因素 A 的不同水平用 $A_1, A_2, \cdots$ 表示。

在一项试验中，如果让一个因素的水平变化，其他因素水平保持不变，这样的试验叫做单因素试验。处理单因素试验的统计推断问题称为单因素方差分析或一元方差分析。类似地可定义多因素方差分析。本节先介绍单因素方差分析。

例6.1 有5种油菜品种，分别在4块试验田上种植，所得亩产量如表6.1所示（单位：*kg*）。

表6.1

品种 \ 田块	1	2	3	4
A_1	256	222	280	298
A_2	244	300	290	275
A_3	250	277	230	322
A_4	288	280	315	259
A_5	206	212	220	212

试问：不同油菜品种对平均亩产量影响是否显著。

例6.2 某种型号化油器的原喉管结构油耗较大，为节约能源，设想了两种改进方案以降低油耗指标——比油耗。现对用各种结构的喉管制造的化油器分别测得如表6.2的数据。

表6.2 原始数据表

指标 / 水平	比油耗							
A_1：原结构	231.0	232.8	227.6	228.3	224.7	225.5	229.3	230.3
A_2：改进方案Ⅰ	22.8	224.5	218.5	220.2				
A_3：改进方案Ⅱ	224.3	226.1	221.4	223.6				

试问：喉管的结构对比油耗的影响是否显著。

从例 1 和例 2 可以看出，在因素 A 的不同水平下，试验数据之间存在有差异，即使在因素 A 的同一个水平下，试验数据之间同样存在差异。那么，试验数据之间的差异到底是由于因素水平变化所引起的呢？还是由于随机误差的干扰所引起的呢？如果是由于因素的水平改变所引起的，那么因素取什么水平，对试验指标最有利？这就是方差分析要解决的问题。下面给出这个问题的数学模型及统计推断方法。

一、数学模型

设在一项试验中，因素 A 有 r 个不同水平 $A_1, A_2, \cdots, A_r$，在水平 A_i 下的试验结果 X_i 服从正态分布 $N(\mu_i, \sigma^2)(i=1,2,\cdots,r)$，且 $X_1, \cdots, X_r$ 相互独立。现在水平 A_i 下做了 n_i 次试验，获得了 n_i 个试验结果 $X_{ij}(j=1,2,\cdots,n_i)$，它可以看成是取自总体 $X_i(i=1,2,\cdots,r)$ 的一个样本（见表 **6.3**）。由于 X_{ij} 服从正态分布 $N(\mu_i, \sigma^2)$，故 X_{ij} 与 μ_i 的差可以看成一个随机误差 ε_{ij}，ε_{ij} 服从正态分布 $(i=1,2,\cdots,r, j=1,2,\cdots,n_i)$。于是单因素方差分析的数学模型可以表示为

$$\left.\begin{aligned} X_{ij} &= \mu_i + \varepsilon_{ij} \\ \varepsilon_{ij} &\sim N(0,\sigma^2) \end{aligned}\right\}, i = 1,2,\cdots,r, j = 1,2,\cdots,n_i, \quad (6.1)$$

其中诸 ε_{ij} 相互独立。我们的任务是检验上述同方差的 r 个正态总体的均值是否相等，即检验假设：

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_r \leftrightarrow H_1 : \mu_1, \mu_2, \cdots, \mu_r$$

中至少有两个不相等。

表6.3

总　体	样　本				样本平均
X_1	X_{11}	X_{12}	$\cdots$	X_{1n_1}	$\overline{X}_1$
X_2	X_{21}	X_{22}	$\cdots$	X_{2n_2}	$\overline{X}_2$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$
X_r	X_{r1}	X_{r2}	$\cdots$	X_{rn_r}	$\overline{X}_r$

记 $\mu=\frac{1}{n}\sum_{i=1}^{r}n_i\mu_i(n=\sum_{i=1}^{r}n_i),\alpha_1=\mu_i-\mu$ 表示因素 A 第 i 水平效应$(i=1,2,\cdots)$，则试验数据的数学模型可写为：

$$X_{ij}=\mu+\alpha_i+\varepsilon_{ij},\quad i=1,2,\cdots,r,\ j=1,2,\cdots,n_i\ 。 \qquad (6.2)$$

单因素方差分析问题即为检验假设

$$H_0:\alpha_1=\alpha_2=\cdots=\alpha_r=0\leftrightarrow H_1,$$

至少有一个$\alpha_i\neq 0(i=1,2,\cdots,r)$是否成立的问题。

二、离差平方和分解与显著性检验

显然，检验假设 H_0 可以用 t 检验法，只要检验任意一个水平的效应 α_i 等于 0，但这样要做 r 次检验，很繁琐。为了简化步骤，可采用下面介绍的离差平方和分解的方法。记

$$\overline{X}_i = \frac{1}{n_i}\sum_{j=1}^{n_i} X_{ij},\quad i = 1,2,\cdots,r, \qquad (6.3)$$

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{r}\sum_{j=1}^{n_i} X_{ij}, \qquad (6.4)$$

其中 $n=\sum_{i=1}^{r} n_i$，$\overline{X}_i$ 是从第 i 个总体中抽得的样本均值，称为组内平均，而 $\overline{X}$ 称为总平均，n 是从 r 个总体中抽得的样本的总容量。

由式（6.3）和式（6.4）可以推得

$$\sum_{i=1}^{r}\sum_{j=1}^{n_i}(X_{ij}-\overline{X}_i)(\overline{X}_i-\overline{X})=0$$

由此得到，总离差平方和为

$$Q_T=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(X_{ij}-\overline{X})^2=\sum_{i=1}^{r}\sum_{j=1}^{n_j}[(X_{ij}-\overline{X}_i)(\overline{X}_i-\overline{X})]^2$$

$$=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(X_{ij}-\overline{X}_i)^2+2\sum_{i=1}^{r}\sum_{j=1}^{n_i}(X_{ij}-\overline{X}_i)(\overline{X}_i-\overline{X})+\sum_{i=1}^{r}\sum_{j=1}^{n_i}(\overline{X}_i-\overline{X})^2$$

$$=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(X_{ij}-\overline{X}_i)^2+\sum_{i=1}^{r}n_i(\overline{X}_i-\overline{X})^2$$

令：

$$Q_E=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(X_{ij}-\overline{X}_i)^2, \qquad (6.5)$$

$$Q_A=\sum_{i=1}^{r}n_i(\overline{X}_i-\overline{X})^2, \qquad (6.6)$$

分别称Q_E与Q_A为组内离差平方和与组间离差平方和。Q_E表示X_{ij}与其组内平均$\overline{X}_i$的离差平方和，它反映了试验误差引起的数据波动，而第二项Q_A是组内平均与总平均的离差平方和，它在一定程度上反映了因素水平的改变引起的数据波动和试验误差引起的数据波动，从而得

$$Q_T = Q_E + Q_A, \qquad (6.7)$$

上式称为总离差平方和分解公式。

下面通过比较Q_E和Q_A的大小来构造检验H_0的统计量。

令 $\bar{\varepsilon}_i=\frac{1}{n}\sum_{j=1}^{n_i}\varepsilon_{ij},\bar{\varepsilon}=\frac{1}{n}\sum_{i=1}^{r}\sum_{j=1}^{n_i}\varepsilon_{ij}$，并将式（6.2）代入式（6.5）和式（6.6）得

$$Q_E=\sum_{i=1}^{r}n_i(\mu+\alpha_i+\varepsilon_{ij}-\mu-\alpha_i-\bar{\varepsilon}_i)^2=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(\varepsilon_{ij}-\bar{\varepsilon}_i)^2$$

$$Q_A=\sum_{i=1}^{r}n_i(\mu+\alpha_i+\bar{\varepsilon}_i-\mu-\bar{\varepsilon})^2=\sum_{i=1}^{r}n_i(\alpha_i+\bar{\varepsilon}_i-\bar{\varepsilon})^2$$

$$=\sum_{i=1}^{r}n_i\sigma_i^2+\sum_{i=1}^{r}n_i(\bar{\varepsilon}_i-\bar{\varepsilon})^2+2\sum_{i=1}^{r}n_i\alpha_i(\bar{\varepsilon}_i-\bar{\varepsilon})$$

由于

$$\varepsilon_{ij}\sim N(0,\sigma^2),\bar{\varepsilon}_i\sim N\left(0,\frac{\sigma^2}{n}\right),i=1,2,\cdots,r,j=1,2,\cdots,n_i$$

从而

$$EQ_E = E\sum_{i=1}^{r}\sum_{j=1}^{n_i}(\varepsilon_{ij}-\bar{\varepsilon}_i)^2 = \sum_{i=1}^{r}(n_i-1)\sigma^2 = (n-r)\sigma^2$$

$$EQ_A = \sum_{i=1}^{r} n_i\alpha_i^2 + (r-1)\sigma^2$$

故有

$$E\left(\frac{Q_E}{n-r}\right) = \sigma^2, \qquad (6.8)$$

$$E\left(\frac{Q_A}{r-1}\right) = \sigma^2 + \frac{1}{r-1}\sum_{i=1}^{r} n_i\alpha_i^2 。 \qquad (6.9)$$

当H_0成立时，即$\alpha_1=\alpha_2=\cdots=\alpha_r=0$时，$E\dfrac{Q_A}{r-1}=E\dfrac{Q_E}{n-r}=\sigma^2$。

否则，$E\dfrac{Q_A}{r-1}\geq E\dfrac{Q_E}{n-r}$，从而当$H_0$不成立时，比值

$$\frac{Q_A/(r-1)}{Q_E/(n-r)}\overset{def}{=\!=}\frac{\overline{Q}_A}{Q_E}=F$$

有偏大的趋势，所以F可作为检验H_0的统计量。

下面我们先求出在H_0成立条件下，统计量F的概率分布。当H_0成立时，所有的α_i都等于零，式（6.2）变成

$$X_{ij}=\mu+\varepsilon_{ij}$$

代入Q_T，Q_E和Q_A的表达式，式（6.7）可写成

$$Q_T=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(\varepsilon_{ij}-\bar{\varepsilon})^2+\sum_{i=1}^{r}\sum_{j=1}^{n_i}(\varepsilon_{ij}-\bar{\varepsilon}_i)^2+\sum_{i=1}^{r}\left[\sqrt{n_i}(\bar{\varepsilon}_i-\bar{\varepsilon})\right]^2$$

又因

$$\sum_{i=1}^{r}\sum_{j=1}^{n_i}\varepsilon_{ij}^2=\sum_{i=1}^{r}\sum_{j=1}^{n_1}(\varepsilon_{ij}-\bar{\varepsilon})^2+n\bar{\varepsilon}^2$$

故

$$\sum_{i=1}^{r}\sum_{j=1}^{n_i}\varepsilon_{ij}^2=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(\varepsilon_{ij}-\bar{\varepsilon}_i)^2+\sum_{i=1}^{r}\left[\sqrt{n_i}(\bar{\varepsilon}_i-\bar{\varepsilon})\right]^2+(\sqrt{n}\bar{\varepsilon})^2$$

上式两边同除以σ^2，左边$\frac{1}{\sigma^2}\sum_{i=1}^{r}\sum_{j=1}^{n_i}\varepsilon_{ij}^2$是自由度为 n 的 χ^2 的变量，右边三项分别为：

$$\frac{1}{\sigma^2}Q_E=\frac{1}{\sigma^2}\sum_{i=1}^{r}\sum_{j=1}^{n_i}(\varepsilon_{ij}-\bar{\varepsilon}_i)^2\ ,$$

有r个约束条件

$$\sum_{j=1}^{n_i}(\varepsilon_{ij}-\bar{\varepsilon}_i)=0(i=1,2,\cdots,r)\ ,$$

通过这r个约束条件，

则$\varepsilon_{ij}(i=1,2,\cdots,r;j=1,2,\cdots,n_i)$

有r个变量可由其它变量线性表示.

所以二次型$\frac{1}{\sigma^2}Q_E$的秩为$n-r$；

$$\frac{1}{\sigma^2}Q_A=\frac{1}{\sigma^2}\sum_{i=1}^{r}\left[\sqrt{n_i}(\bar{\varepsilon}_i-\bar{\varepsilon})\right]^2,$$

有一个约束条件

$$\sum_{i=1}^{r}n_i(\bar{\varepsilon}_i-\bar{\varepsilon})=0,$$

所以 $\frac{Q_A}{\sigma^2}$ 的秩为 $r-1$；$\frac{1}{\sigma^2}(\sqrt{n}\bar{\varepsilon})^2$ 的自由度是 1，它们的自由度之和为 $(n-r)+(r-1)+1=n$，由柯赫伦分解定理（P127）知，$\frac{Q_E}{\sigma^2}$ 服从自由度为 $n-r$ 的 χ^2 分布，$\frac{Q_A}{\sigma^2}$ 服从自由度为 $r-1$ 的 χ^2 分布，且 $\frac{Q_E}{\sigma^2}$ 与 $\frac{Q_A}{\sigma^2}$ 相互独立。

由 F 分布的定义知，在 H_0 成立的条件下，

$$F=\frac{Q_A/\sigma^2(r-1)}{Q_E/\sigma^2(n-1)}=\frac{Q_A/(r-1)}{Q_E/(n-r)}=\frac{\overline{Q}_A}{\overline{Q}_E}$$

服从自由度为 $(r-1,n-r)$ 的 F 分布。

给定显著性水平 α，如何确定小概率事件呢？

由式（6.8）与式（6.9）可知当 H_0 成立时，

$$E\left(\frac{Q_A}{r-1}\right)=E\left(\frac{Q_E}{n-r}\right);$$

当 H_0 不成立时，

$$E\left(\frac{Q_A}{r-1}\right)>E\left(\frac{Q_E}{n-r}\right)。$$

因此，F的值有偏大的趋势。

于是可以从 F 分布数值表中查得 $F_\alpha(r-1,n-1)$ 的值，使

$$P\{F \geq F_\alpha(r-1,n-r)\} = \alpha$$

一次抽样后由样本值计算得 F 的数值，

若

$$F \geq F_\alpha(r-1,n-r),$$

则拒绝假设 H_0，即可认为在显著水平 α 下，因素的不同水平对试验结果有显著影响；

若

$$F < F_{\alpha}(r-1, n-r),$$

则接受假设H_0，即可认为在显著性水平α下，因素的不同水平对试验结果无显著影响。 将以上分析列成方差分析表6.4

表6.4

方差来源	离差平方和	自由度	平均离差平方和	F 值	显著性
组　间	$Q_A = \sum_{i=1}^{r} n_i (\overline{X}_i - \overline{X})^2$	$r-1$	$\overline{Q}_A = \dfrac{Q_A}{r-1}$	$F = \dfrac{\overline{Q}_A}{Q_E}$	
组　内	$Q_E = \sum_{i=1}^{r} \sum_{j=1}^{n_i} (X_{ij} - \overline{X}_i)^2$	$n-r$	$\overline{Q}_E = \dfrac{Q_E}{n-r}$		
总　和	$Q_T = \sum_{i=1}^{r} \sum_{j=1}^{n_i} (X_{ij} - \overline{X})^2$	$n-1$			

上一页　下一页

需要指出，表 6.4 中的Q_T在计算F时并没有用到，它只用以核对$Q_T = Q_A + Q_E$是否成立，起校核作用，其中显著性一栏，当$\alpha = 0.05$时，若检验显著，打一个“*”号，当$\alpha = 0.01$，若检验显著，打 2 个“* *”号，表示因素A影响高度显著。

为方便起见，计算F值时常常采用下面的公式：

$$Q = \sum_{i=1}^{r} \frac{1}{n_i} \left(\sum_{j=1}^{n_i} X_{ij} \right)^2, \quad P = \frac{1}{n} \left(\sum_{i=1}^{r} \sum_{j=1}^{n_i} X_{ij} \right)^2, \quad R = \sum_{i=1}^{r} \sum_{j=1}^{n_i} X_{ij}^2 . \quad (6.10)$$

可以证明：

$$Q_A = Q - P, Q_E = R - Q, Q_T = R - P$$

例 6.3　对上面例 4.2 中提供的试验数据，在显著性水平 $\alpha = 0.01$ 条件下进行方差分析。判断喉管的结构对比油耗的影响是否有显著差异？

解　将所有原始数据减去 220 后进行计算，见表 6.5 的数据 $(X'_{ij} = X_{ij} - 220)$。

表6.5　变换后的数据表

水平	X'_{ij}							
A_1	11.0	12.8	7.6	8.3	4.7	5.5	9.3	10.3
A_2	2.8	4.5	−1.5	0.2				
A_3	4.3	6.1	1.4	3.6				

本例中，

$$r=3, n_1=8, n_2=4, n_3=4, n=\sum_{i=1}^{3} n_i = 16$$

$$P' = \frac{1}{n}\left(\sum_{i=1}^{3}\sum_{j=1}^{n_i} X_{ij}^{'}\right)^2 = 516.43$$

$$Q' = \sum_{i=1}^{3}\frac{1}{n_i}\left(\sum_{j=1}^{n_i} X_{ij}^{'}\right)^2 = 672.07$$

$$R' = \sum_{i=1}^{3}\sum_{j=1}^{n_i} X_{ij}^{'2} = 757.74$$

$$Q_A^{'} = Q' - P' = 155.64, \quad Q_T^{'} = R' - P' = 240.98$$

$$Q_E^{'} = R' - Q' = 85.34$$

方差分析见表6.6：

表6.6　方差分析表

方差来源	离差平方和	自由度	均方离差	F 值	显著性
组　间	155.64	2	77.82	11.86	* *
组　内	85.34	13	6.56		
总　和	240.98	15			

对 $\alpha = 0.01$，查 F 分布表得 $F_{0.01}(2,13) = 6.70$，由于

$$F = 11.86 > 6.70 = F_{0.01}(2,13),$$

故可认为不同的喉管结构的比油耗有显著差异，从 $\overline{X}_i$ 的大小可以知道，改进方案 1 的比油耗最小，采用这种结构有可能节省油耗。

三、参数估计

若用 $\hat{\alpha}_i, \hat{\mu}_i, \hat{\mu}, \hat{\sigma}^2$ 分别表示 α_i, μ_i, μ 及 $\hat{\sigma}^2$ 的估计，则有

$$\begin{cases} \hat{\alpha}_i = \overline{X}_i - \overline{X}, & i = 1, 2, \cdots, r, \\ \hat{\mu}_i = \overline{X}_i, & i = 1, 2, \cdots, r, \\ \overline{\mu} = \overline{X}, \\ \hat{\sigma}^2 = Q_E/(n-r) = \overline{Q}_E, \end{cases} \tag{6.11}$$

可以证明上述估计都是无偏估计。

在单因素方差估计中，如果检验结果为 H_0 不成立，有时需要对 $\mu_i - \mu_k$ 作区间估计。

为此可用 $\overline{X}_i = \overline{X}_k$ 作为 $\mu_i - \mu_k$ 的点估计。

由式（6.2）

$$\overline{X}_i - \overline{X}_k = \mu_i - \mu_k + (\overline{\varepsilon}_i - \overline{\varepsilon}_k)。$$

由于 $\overline{X}_i = \overline{X}_k$ 服从正态分布

$$N\left(\mu_i - \mu_k, \left(\frac{1}{n_i} + \frac{1}{n_k}\right)\sigma^2\right),$$

故

$$\frac{\overline{X}_i - \overline{X}_k - (\mu_i - \mu_k)}{\sqrt{\frac{1}{n_i} + \frac{1}{n_k}}\sigma}$$

服从标准正态公布 $N(0,1)$，

又考察随机变量

$$\frac{1}{\sigma^2}Q_E=\frac{1}{\sigma^2}\sum_{i=1}^{r}\sum_{j=1}^{n_i}(\bar{\varepsilon}_{ij}-\bar{\varepsilon}_i)^2,$$

由χ^2变量的可加性，它服从自由度为$n-r$的 χ^2分布。

不难证明，$\bar{\varepsilon}_i-\bar{\varepsilon}_k$与$Q_E$是相互独立的，又$E\bar{Q}_E=\sigma^2$，所以

$$T=\frac{\bar{X}_i-\bar{X}_k-(\mu_i-\mu_k)}{\sqrt{\left(\frac{1}{n_i}+\frac{1}{n_k}\right)\bar{Q}_E}}$$

服从自由度为$n-r$的t分布。

给定显著性水平α，查t分布表可得$t_{\alpha/2}(n-r)$，使得

$$P\{|T|<t_{\alpha/2}(n-r)\}=1-\alpha,$$

即

$$P\left\{\bar{X}_i-\bar{X}_k-t_{\alpha/2}(n-r)\sqrt{\left(\frac{1}{n_i}+\frac{1}{n_k}\right)\bar{Q}_E}<\mu_i-\mu_k\right.$$

$$\left.<\bar{X}_i-\bar{X}_k+t_{\alpha/2}(n-r)\sqrt{\left(\frac{1}{n_i}+\frac{1}{n_k}\right)\bar{Q}_E}\right\}=1-\alpha$$

故$\mu_i-\mu_k$的置信概率为$1-\alpha$的置信区间为

$$\left(\overline{X}_i-\overline{X}_k\pm t_{\alpha/2}(n-r)\sqrt{\overline{Q}_E\left(\frac{1}{n_i}+\frac{1}{n_k}\right)}\right)。\qquad(6.12)$$

例 6.4（续例 6.1）　对例 6.1 中的数据，试问：

（1）不同品种对亩产量有无显著影响；

（2）求 $\mu_1-\mu_5$ 的置信度为 0.95 的置信区间。

解　（1）令 X_{ij} 表示第 i 个品种在第 j 块试验田的亩产量，$i=1,2,3,4,5, n_1=n_2=\cdots=n_5=4, n=20$。由公式（6.10）计算得

$$R=\sum_{i=1}^{5}\sum_{j=1}^{4}x_{ij}^2=1395472,\quad Q=\frac{1}{4}\sum_{i=1}^{5}\left(\sum_{j=1}^{4}x_{ij}\right)^2=1383980.5$$

$$P=\frac{1}{20}\left(\sum_{i=1}^{5}\sum_{j=1}^{4}x_{ij}\right)^2=\frac{(5236)^2}{20}=1370784.8$$

$$Q_T=R-P=1395472-1370784.8=24687.2$$

$$Q_A = Q - P = 1383980.5 - 1370784.8 = 13195.7$$

$$Q_E = Q_T - Q_A = 24687.2 - 13195.7 = 11491.5$$

根据以上数据列方差分析表如下（表6.7）。

表6.7　方差分析表

方差来源	离差平方和	自由度	平均平方和	F 值	显著性
组　间	13195.7	4	3298.925	4.31	*
组　内	11491.5	15	766.1		
总　和	24687.2	19			

对于 $\alpha = 0.05$，查 F 表得 $F_{0.05}(4,15) = 3.06$，

由于 $F = 4.31 > 3.06 = F_{0.05}(4,15)$，从而知因素 A 影响显著，即不同品种对平均亩产量有显著影响。

（2）
$$\bar{x}_1 = \frac{1}{4} \times (256 + 222 + 280 + 298) = 264$$

$$\bar{x}_5 = \frac{1}{4} \times (206 + 212 + 220 + 212) = 212.5$$

对 $\alpha = 0.05$，$n - r = 20 - 5 = 15$，查 t 分布表得 $t_{0.025}(15) = 2.1315$，故由公式（6.12）得 $\mu_1 - \mu_5$ 的置信度为 0.95 的置信区间为

$$\left[\bar{x}_1 - \bar{x}_5 \pm t_{0.025}(15) \sqrt{\bar{Q}_E \left(\frac{1}{4} + \frac{1}{4} \right)} \right]$$

$$= \left[264 - 212.5 \pm 2.1315 \times \sqrt{\frac{1}{2} \times 766.1} \right]$$

$$= \left[51.5 - 2.1315 \times 19.6, 51.5 + 2.1315 \times 19.6 \right] = (9.7, 93.3)$$